



MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 1

Análisis Exploratorio e Inferencial

Informe técnico grupal · 20 %

Título del proyecto: Duración de la titulación en el pregrado universitario chileno (2025)

Integrantes: Fernanda Ovalle Román
Sebastián Cajales Cid
César Lorca Bacián
Jorge Álvarez Ossandón

Dataset: Titulados de Educación Superior 2025 – Datos Abiertos Mineduc

Docente: Jean Paul Maidana González

Fecha: 14/10/2026

Repositorio GitHub: <https://github.com/jaossandon/sumativa1-f2-mcdi501>

Información de la evaluación

Fase del proyecto: Fase 2: Búsqueda y recopilación de información

Modalidad: Grupal (3–4 integrantes) **Ponderación:** 20 % de la nota final

Entregables: Informe PDF (máx. 8 págs., sin anexos) · Notebook .ipynb · Repositorio GitHub

Resultado de aprendizaje (RA1): aplicar probabilidad e inferencia estadística en problemas de decisión bajo incertidumbre.

Indicadores: ID1.2, ID1.3, ID1.4.

Recuerden: los resultados de esta sumativa serán la entrada de S2 y S3.

Índice

1	Preparación y carga de datos	2
2	Análisis exploratorio de datos	2
3	Estimación de parámetros	4
4	Pruebas de hipótesis	5
5	Informe de avance del proyecto	6
6	Notebook y repositorio GitHub	6
7	Bibliografía	7

1. Preparación y carga de datos

Se utilizó el registro de Titulados de Educación Superior 2025 publicado por el Centro de Estudios del Mineduc (328.998 registros y 41 variables, separador ;, codificación UTF-8). Se trabajó desde el archivo crudo y no desde la versión procesada del curso anterior, porque esta incluía imputación por mediana, codificación *one-hot* y escalado robusto. Esas transformaciones alteran las unidades y la varianza de las variables, y por lo tanto invalidan la estimación por intervalos y las pruebas de hipótesis.

La población de estudio se restringió a titulados de pregrado en universidades (105.063 registros; 31,9% del archivo). Se clasificaron las variables en numéricas (duraciones en semestres), fechas codificadas como enteros (nacimiento, ingreso y titulación), categóricas codificadas como números (sexo y códigos institucionales), categóricas de texto (tipo de institución, región, jornada, modalidad, área) e identificadores. A partir de las fechas se construyeron las dos variables de interés: **semestres reales hasta la titulación**, contados de forma inclusiva desde el semestre de ingreso hasta el de titulación, y **edad al titularse**, en años con decimales. Esto fue necesario porque `dur_total_carr` corresponde a la duración formal del plan y no al tiempo efectivo de cada titulado.

Revisión	Casos	%	Decisión
Filas duplicadas idénticas	0	0,00	Ninguna que eliminar
Personas con más de un título	922	0,88	Conservadas (unidad = titulación)
Columnas constantes tras el filtro	3	–	Eliminadas
Sin año/semestre de ingreso (1900/0)	13.396	12,75	NaN + bandera, sin imputar
Titulación antes de la duración formal	1.511	1,44	Marcadas
Atípicos en semestres reales (Tukey)	13.201	12,56	Marcados, no eliminados
Atípicos en edad de titulación (Tukey)	10.711	10,19	Marcados, no eliminados

Tabla 1: Reporte de calidad sobre la población de estudio ($n = 105.063$).

El faltante en el año de ingreso no es aleatorio, ya que se concentra en planes de continuidad de estudios. Por eso se recodificó como valor faltante con una bandera, sin imputar, para no reducir artificialmente la varianza. Los atípicos se conservaron: representan la cola larga natural de una distribución asimétrica, es decir, los titulados que demoran más, que son precisamente el objeto de la pregunta de investigación. Eliminarlos sesgaría la media y la varianza hacia abajo.

2. Análisis exploratorio de datos

Como variable respuesta se utilizó el **atraso**, definido como los semestres reales hasta la titulación menos la duración formal del plan. Esta variable aísla el comportamiento del estudiante del diseño de la carrera: su correlación con la duración formal es prácticamente nula (Spearman $\rho = 0,01$), lo que indica que el retraso no es un fenómeno propio de las carreras largas.

Variables numéricas. Las tres variables de comportamiento presentan asimetría positiva marcada: semestres reales (media 12,99; mediana 12; asimetría 3,33), atraso (media 3,40; mediana 2; RIC 1–4; asimetría 4,41) y edad al titularse (media 27,97; mediana 25,58; asimetría 2,22). El titulado típico demora dos semestres más que lo establecido en su plan, pero una cola extensa de casos con atrasos mayores eleva la media (Figura 1). En consecuencia, la mediana y el rango intercuartílico describen mejor el caso típico que la media y la desviación estándar.




Figura 1: Distribución de semestres reales y edad al titularse. Histogramas truncados en el percentil 99; los boxplots usan el mismo eje y los valores extremos se incluyen en todos los cálculos.

Variables categóricas. Los titulados se distribuyen en universidades privadas (47,1%), privadas CRUCH (27,8%) y estatales CRUCH (25,1%). Predomina la jornada diurna (78,2%), seguida de la vespertina (11,8%); el 56,3% son mujeres, y Tecnología y Salud concentran el 44% de los titulados (Figura 2). La mitad de los titulados estudió en la Región Metropolitana. Las categorías con menos de 1% de los casos se excluyen de las comparaciones por falta de tamaño muestral.




Figura 2: Frecuencias relativas de las principales variables categóricas ($n = 105.063$).

Análisis bivariado. Dada la asimetría, se privilegió la correlación de Spearman sobre la de Pearson, que resultó sistemáticamente menor por el efecto de los valores extremos (p.ej., semestres

reales y duración formal: $\rho = 0,48$ frente a $r = 0,34$). La edad al titularse se asocia positivamente con el atraso ($\rho = 0,47$), relación que es en parte mecánica. Al comparar grupos, las medianas del atraso coinciden (2 semestres), pero las diferencias aparecen en la cola: los hombres presentan una media de 4,00 semestres frente a 2,93 en mujeres, y en la jornada vespertina el 32,9 % supera los cuatro semestres de atraso, frente al 23,9 % en la diurna (Figura 3). Estas dos diferencias motivan las pruebas de hipótesis de la Sección 4. Se observó además que el 76 % de los titulados a distancia carece de año de ingreso, por lo que esa jornada no se incluye en las comparaciones.




Figura 3: Atraso según sexo (rombo: media; atípicos omitidos) y proporción de titulados con atraso superior a cuatro semestres según jornada.

3. Estimación de parámetros

Se estimaron la media y la mediana poblacionales de tres variables numéricas: el atraso respecto de la duración formal (`atraso_semestres`), la duración real de la carrera (`semestres_reales`) y la edad de titulación (`edad_titulacion`). Para la media se usó el intervalo t al 95 %, $\bar{x} \pm t_{0,975; n-1} s/\sqrt{n}$, que es válido aquí por el teorema central del límite dado el gran tamaño muestral, aun cuando las variables son marcadamente asimétricas. Como esa asimetría (coeficientes entre 2 y 4,4) hace que la media quede arrastrada por la cola derecha, se estimó además la mediana con un intervalo bootstrap de percentiles ($B = 2000$ remuestras, semilla 42), que no supone ninguna distribución.

Tabla 2: Estimaciones puntuales e intervalos de confianza al 95 %.

Variable	n	Media	IC 95 % media	Mediana	IC 95 % mediana (boot.)
Atraso (semestres)	91 667	3,40	[3,37; 3,43]	2,00	[2,00; 2,00]
Semestres reales	91 667	12,99	[12,95; 13,02]	12,00	[12,00; 12,00]
Edad de titulación (años)	105 063	27,97	[27,93; 28,00]	25,58	[25,58; 25,67]

Interpretación. Con un 95 % de confianza, el titulado de pregrado universitario tarda en promedio entre 3,37 y 3,43 semestres más que la duración formal de su carrera, aunque el caso típico (la mediana) se atrasa 2 semestres, es decir, un año. La diferencia entre media y mediana, de casi un semestre y medio, confirma que un grupo minoritario con atrasos muy largos eleva el promedio. Lo mismo ocurre con la edad: la mediana es 25,6 años, pero la media sube a 28 años por los titulados de mayor edad. Por esa razón la mediana es el indicador más representativo.

Precisión y limitaciones. Los intervalos son muy estrechos (ancho cercano a 0,06) por el gran tamaño de la muestra. Los de la mediana de atraso y de semestres tienen ancho cero porque esas variables son enteras y una gran cantidad de titulados está justo en el valor mediano, de

modo que la mediana no cambia entre remuestras. En edad, el ancho equivale a un mes, que es la resolución del dato. Por eso la incertidumbre por muestreo es despreciable, y las limitaciones relevantes son de sesgo: (i) se observa solo a quienes *se titularon*, por lo que no hay información de quienes desertan o siguen estudiando; (ii) el 12,75 % de los registros no tiene año de ingreso y queda fuera de las estimaciones de atraso y semestres; y (iii) la cohorte corresponde a un único año de titulación (2025).

4. Pruebas de hipótesis

Se plantearon dos pruebas con nivel de significancia $\alpha = 0,05$. Este valor convencional es adecuado porque el análisis es exploratorio: un falso positivo no conduce a una decisión irreversible, sino a orientar análisis posteriores. Dado el gran tamaño muestral, que hace significativa casi cualquier diferencia, cada prueba se acompaña de su tamaño de efecto para juzgar su relevancia práctica.

Prueba 1: atraso según sexo (*t* de Welch)

$H_0 : \mu_H = \mu_M$ frente a $H_1 : \mu_H \neq \mu_M$, donde μ es el atraso medio en semestres.

Supuestos. (i) Independencia: cada registro es un titulado distinto y los grupos no se solapan. (ii) Normalidad: el atraso es muy asimétrico, pero con $n_H = 40\,075$ y $n_M = 51\,592$ el teorema central del límite garantiza la normalidad aproximada de las medias. Como respaldo se aplicó la prueba de Mann–Whitney, que no supone normalidad. (iii) Homogeneidad de varianzas: la prueba de Levene la rechaza ($W = 735,7$; $p < 10^{-160}$; $s_H = 5,43$ frente a $s_M = 4,10$), lo que justifica usar Welch en lugar de la *t* clásica.

Resultado. $t = 32,76$ ($gl \approx 72\,374$; $p < 10^{-200}$), por lo que se rechaza H_0 . Mann–Whitney coincide ($p \approx 0$). Los hombres se atrasan en promedio 1,07 semestres más que las mujeres (IC 95 % [1,00; 1,13]), con un tamaño de efecto pequeño (d de Cohen = 0,23).

Prueba 2: jornada y atraso alto (*chi*-cuadrado de independencia)

Se define *atraso alto* como un atraso mayor que 4 semestres (el tercer cuartil). H_0 : el atraso alto es independiente de la jornada (diurna o vespertina); H_1 : existe asociación.

Supuestos. Observaciones independientes y frecuencias esperadas mayores que 5 en todas las celdas (la mínima es 1 933). Con este tamaño muestral no se aplicó la corrección de Yates.

Tabla 3: Atraso alto según jornada (frecuencias observadas y porcentaje por fila).

Jornada	Sin atraso alto	Con atraso alto	% atraso alto
Diurna	61 679	19 322	23,9
Vespertina	5 260	2 581	32,9

Resultado. $\chi^2 = 316,1$ ($gl = 1$; $p < 10^{-69}$), por lo que se rechaza H_0 . La proporción de atraso alto en la jornada vespertina supera en 9 puntos porcentuales a la diurna, lo que equivale a un riesgo 1,38 veces mayor. La asociación es, sin embargo, débil (V de Cramér = 0,06).

Implicancias prácticas

Ambas diferencias son estadísticamente sólidas, pero de magnitud pequeña: sexo y jornada explican una parte menor de la variación del atraso. En ambos casos la diferencia se concentra en la cola de atrasos largos más que en el caso típico (la mediana es 2 en hombres y en mujeres). Para la gestión institucional, esto sugiere que la jornada vespertina, cuyos estudiantes suelen

compatibilizar estudio y trabajo, es un foco razonable de acompañamiento. Sin embargo, son asociaciones y no causas: ambas variables pueden estar mezcladas con el área de conocimiento, el tipo de institución o la edad de ingreso, lo que se abordará en las etapas siguientes con modelos multivariados.

5. Informe de avance del proyecto

Introducción. La duración formal de una carrera es un supuesto de planificación para estudiantes, familias e instituciones, y también para el financiamiento público. Este avance cuantifica cuánto se aparta de ella la trayectoria real de los titulados de pregrado universitario en Chile en 2025, y si ese desvío difiere según el sexo y la jornada.

Métodos. Se partió del registro administrativo de titulados del Mineduc (2025), filtrado a pregrado universitario (105 063 registros). Los códigos de relleno se trataron como faltantes, sin imputar, y los valores atípicos se marcaron pero no se eliminaron. A partir de las fechas de ingreso y titulación se construyó el atraso en semestres respecto de la duración formal. Se aplicaron estadística descriptiva y correlación de Spearman, intervalos de confianza al 95 % (t para la media y *bootstrap* para la mediana) y dos pruebas de hipótesis (t de Welch y *chi*-cuadrado) con sus tamaños de efecto.

Resultados. El titulado típico egresa con 2 semestres (un año) de atraso; el promedio es de 3,40 semestres (IC 95 % [3,37; 3,43]), elevado por una cola de atrasos largos. La mediana de la edad de titulación es 25,6 años. El atraso no se relaciona con la duración formal de la carrera ($\rho \approx 0$), pero sí con la edad ($\rho = 0,47$). Los hombres se atrasan 1,07 semestres más que las mujeres ($d = 0,23$), y la jornada vespertina presenta 9 puntos porcentuales más de atraso alto que la diurna (V de Cramér = 0,06). Ambas diferencias son significativas ($p < 0,001$), aunque de magnitud pequeña.

Interpretación. Titularse a tiempo es la excepción: la duración formal subestima en alrededor de un año la duración efectiva para el caso típico, y en varios años para una minoría relevante. El sexo y la jornada aportan diferencias reales, pero explican una fracción menor del atraso, lo que indica que hay otros factores, aún no analizados, que pesan más. Las conclusiones se limitan a quienes se titularon: no incluyen a quienes desertaron ni a quienes siguen estudiando, por lo que probablemente subestiman el atraso del sistema.

Próximos pasos. (i) Incorporar el área de conocimiento, el tipo de institución y la edad de ingreso en un modelo multivariado (regresión para el atraso, o logística para el atraso alto) que permita separar el efecto de cada factor. (ii) Estudiar las carreras con mayor atraso mediano para identificar focos de intervención. (iii) Evaluar la sensibilidad de los resultados a los registros sin año de ingreso (12,75 %). (iv) Complementar con datos de matrícula, que sí incluyen a quienes no se titulan, para estimar el atraso del sistema completo.

6. Notebook y repositorio GitHub

El análisis completo está en el notebook `notebooks/Sumativa1_F2_Titulados.ipynb` del repositorio <https://github.com/jaossandon/sumativa1-f2-mcdi501>. El notebook sigue el mismo orden que este informe (secciones 1 a 4), documenta cada decisión en celdas de texto y genera todas las tablas y figuras, que se guardan en `informe/figuras/`. Para reproducirlo se crea un entorno con Python 3.13 y `pip install -r requirements.txt`, se coloca el archivo crudo del Mineduc en `data/raw/` (no se versiona por su tamaño) y se ejecutan las celdas en orden. Los procedimientos aleatorios usan una semilla fija (42). El análisis se realizó con *pandas*, *NumPy*, *SciPy* y *Matplotlib* (McKinney, 2010; Virtanen et al., 2020).

7. Bibliografía

- Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2.^a ed.). Lawrence Erlbaum Associates.
- Efron, B. y Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall/CRC. <https://doi.org/10.1201/9780429246593>
- McKinney, W. (2010). Data structures for statistical computing in Python. En S. van der Walt y J. Millman (Eds.), *Proceedings of the 9th Python in Science Conference* (pp. 56–61). <https://doi.org/10.25080/Majora-92bf1922-00a>
- Ministerio de Educación [Mineduc]. (2025). *Titulados de educación superior 2025* [Conjunto de datos]. Servicio de Información de Educación Superior. <https://datosabiertos.mineduc.cl>
- Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., ... SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17(3), 261–272. <https://doi.org/10.1038/s41592-019-0686-z>
- Welch, B. L. (1947). The generalization of “Student’s” problem when several different population variances are involved. *Biometrika*, 34(1–2), 28–35. <https://doi.org/10.1093/biomet/34.1-2.28>