

MAGÍSTER EN CIENCIA DE DATOS E IA · MCDI501: ESTADÍSTICA COMPUTACIONAL

Modelamiento Predictivo Integrado del Atraso Académico en Educación Superior

Bloque 4: Estabilidad Bootstrap, Impacto de la Imputación y Recomendaciones

Expositor: Sebastián Cajales Cid (Bloque 4)
Equipo: Fernanda Ovalle Román · Jorge Álvarez Ossandón · César Lorca Bacián · Sebastián Cajales Cid

Estabilidad Bootstrap (B ≥ 1.000) y Diagnóstico de Supuestos

Universidad Andrés Bello

Evaluación de Estabilidad por Remuestreo

- **Motivación metodológica:** La inferencia asintótica tradicional (Wald) asume normalidad e independencia estricta. La S2 demostró correlación intra-universidad mediante Jackknife.
- **Configuración computacional:** B = 1.000 réplicas no paramétricas sobre el conjunto de Train (70 %, n = 64.167).
- **Intervalos al 95 %:** Cálculo de intervalos Percentil y BCa (Bias-Corrected and Accelerated) para cada coeficiente beta y Odds Ratio.
- **Resultado clave:** Alta estabilidad paramétrica. Ningún intervalo de las variables principales cruza el 1.0 (significancia robusta en Jornada Vespertina, Edad y Tecnología).

Verificación de Supuestos Logísticos

- **Multicolinealidad (VIF):** Factores de Inflación de Varianza controlados (VIF < 5 en todas las variables continuas y dummies).
- **Linealidad en el Logit (Box-Tidwell):** Contraste de términos X · ln(X) para edad de titulación y duración, validando la relación lineal con el log-odds.
- **Residuos Deviance y Pearson:** Distribución simétrica de residuos deviance, sin agrupamientos anómalos ni sobredispersión residual severa.
- **Observaciones Influyentes (Cook):** Análisis de Distancia de Cook y apalancamiento (leverage). Ausencia de casos únicos que determinen los Odds Ratios.

Impacto Analítico de la Estrategia de Imputación

Universidad Andrés Bello

1. Eliminación Listwise

Complete-case analysis · n = 91.667 (-12,75 %)

- **Pérdida muestral:** Descarta 13.396 estudiantes reales.
- **Sesgo potencial:** Subrepresenta programas vespertinos y convalidaciones (patrón MAR).
- **Odds Ratios:** Signos preservados pero intervalos más anchos por menor n.
- **Veredicto:** Inconveniente para políticas institucionales integrales.

2. Imputación Simple

Mediana condicionada · n = 105.063 (100 %)

- **Recuperación:** Recupera todas las filas faltantes.
- **Distorsión:** Comprime artificialmente la varianza e infla la precisión estadística.
- **Correlaciones:** Atenúa la covarianza natural atraso-edad.
- **Veredicto:** Riesgo de subestimar el error estándar real.

3. Regresión Múltiple

Imputación inteligente · n = 105.063 (100 %)

- **Fundamento S1/S2:** Usa predictores con correlación robusta (edad, duración, área, jornada).
- **Covarianza:** Preserva la estructura multivariada de los datos.
- **Desempeño Test:** Mantiene alta capacidad predictiva (AUC sólido en Test).
- **Veredicto:** Estrategia recomendada: máxima potencia sin sesgo.

Progresión Metodológica Integrada: S1 → S2 → S3

Universidad Andrés Bello

Fase 1: Sumativa 1 | Diagnóstico Exploratorio e Inferencia

- Identificación de 12,75 % de faltantes administrativos (1900/0 en ingreso original).
- Atraso medio de 3,4 semestres con fuerte asimetría positiva (mediana = 2).
- Correlación moderada atraso-edad (rho = 0,47) y brechas iniciales por sexo y jornada.
- Detección de 13.201 atípicos según Tukey (decisión clave: conservarlos).

Fase 2: Sumativa 2 | Validación Computacional y Remuestreo

- Bootstrap BCa (B = 10.000): Correlaciones son auténticamente estables y lineales.
- Análisis de Robustez: Atípicos afectan magnitud de colas pero no alteran la dirección.
- Jackknife por Institución: Evidenció dependencia jerárquica intra-universidad.
- Efecto Simpson: La brecha por sexo se reduce a la mitad al controlar por área.

Fase 3: Sumativa 3 | Modelamiento Predictivo y Robustez

- Imputación por Regresión: Recupera los 13.396 casos basándose en correlaciones de S1/S2.
- Regresión Logística: Clasificación supervisada de 'Atraso Alto' (> 4 semestres).
- Bootstrap del Modelo: IC al 95 % confirman estabilidad de Odds Ratios sin asunciones asintóticas.
- Evaluación de Impacto: La imputación robustece la precisión sin alterar la política.

Recomendaciones Estratégicas para la Toma de Decisiones

1. Sistemas de Alerta Temprana Diferenciados

- **Focalización Curricular:** El riesgo de atraso severo se concentra intensamente en facultades de Tecnología, Ciencias e Ingeniería. Las tutorías de titulación deben priorizarse en estas áreas.
- **Flexibilidad en Jornada Vespertina:** La brecha estructural de +9 pp en atraso alto en jornada vespertina exige mecanismos de graduación no presenciales, talleres de tesis en fin de semana y flexibilidad de plazos administrativos.

2. Flexibilización en Gratuidad y Acreditación

- **Revisión de Plazos de Cobertura:** El atraso superior a 4 semestres es un fenómeno estructural (no un hecho aislado). Los beneficios de gratuidad y becas deben contemplar semestres de gracia ajustados a la tasa real de egreso por carrera.
- **Métricas de Acreditación (CNA):** Evaluar la sobre-duración considerando la composición de matrícula (jornada vespertina y áreas STEM) para no penalizar a instituciones con poblaciones de mayor complejidad formativa.

¡Muchas gracias por su atención! · MCDI501 · Grupo 6 (Fernanda Ovalle, César Lorca, Jorge Álvarez, Sebastián Cajales)